

El destino del crédito llega en texto libre; etiquetarlo automáticamente lo convierte en una señal de riesgo y de producto.

6,691 respuestas de solicitudes PyME, en español

10 etiquetas; una respuesta puede tener varias

Métrica principal, fijada antes de modelar: macro FI

Respuesta	Etiquetas
Invertiré en equipo de transporte tractocamion	equ
Compra de inventario publicidad y capacitacion	inv, mkt
transferir otro crédito que está muy caro	cred
Quiero irme de vacaciones en mayo	no

Los datos traían defectos estructurales; los reparamos y documentamos en vez de descartar filas.

6,679 filas en el archivo; el brief dice 6,726

6,691 respuestas limpias tras reparar

58 grupos contradictorios: ruido de anotación medible


Problema	Alcance	Decisión
Registros fusionados en una celda por saltos de línea	unos 22 registros	recuperados línea por línea
Mojibake (crÃ©dito en vez de crédito)	cerca de 42% de las filas	corregido con ftfy
Texto sin sentido o no textual	9 + 1 filas	eliminadas, con su motivo registrado
Texto idéntico con etiquetas distintas	58 grupos	se conservan, siempre del mismo lado de la partición
inv no aparece en el codebook	34.7% de las respuestas	supuesto: inventario o mercancía

Las etiquetas están muy desbalanceadas: inv aparece en 34.7% de las respuestas y temp solo en 2.8%.

86% con una etiqueta, 12.6% con dos, 1% con tres

no casi nunca se combina: solo 4 respuestas

Respuestas cortas: mediana de 11 palabras




Porcentaje de respuestas con la etiqueta (6,691 respuestas limpias)

El test se separó al inicio y se usó una sola vez; modelo, mezcla y umbrales se eligieron con validación cruzada agrupada.

Grupos por texto normalizado:
sin duplicados entre lados


Estratificación iterativa: temp y
sueldo en cada fold

Features de segunda etapa,
siempre out-of-fold



Grupo = texto normalizado (ftfy, minúsculas, espacios): un texto repetido nunca queda a ambos lados. Estratificación iterativa multietiqueta sobre los grupos.

El modelo final mezcla un e5 con fine-tuning y TF-IDF con regresión logística, porque se equivocan en respuestas distintas.




TF-IDF es una línea base difícil de superar: solo el fine-tuning la supera, y mezclar ambos da el mejor resultado.


Embeddings congelados: 0.601,
debajo de B2 (0.671)

e5 con fine-tuning: 0.701;
mezcla E9b: 0.715

Umbrales y reglas: de 0.664 a
0.671




En test, E9b supera a B2 por 0.043 de macro F1 y su Hamming loss queda debajo del baseline de la empresa.



Diferencia pareada en macro F1: +0.043 [+0.020, +0.065]

Su "67% de precisión": mean PR-AUC 0.779, micro 0.749

temp es la etiqueta más débil, con F1 de 0.40 en test, porque su definición mezcla temporada y ciclo de cobro.



161 respuestas temp en CV; 4 mencionan ambos

17% de las respuestas temp pierde la etiqueta ante inv


28 positivos en test: IC de F1 de 0.24 a 0.55

La mayor parte del error restante está en las etiquetas y en el codebook, no en el modelo.

Solo 12% de 50 errores
revisados es del modelo

cleanlab marca 24.8% de CV:
cota superior

equ vs inv: 102 equ predichos
como inv, 53 al revés




E9b responde en 31.7 ms en CPU y manda a revisión humana los casos de riesgo o cercanos al umbral.



E9b (seleccionado)

Etiquetas: cred

Requiere revisión humana: etiqueta de riesgo: cred



Demo en vivo: misma API, sin conexión a internet

La siguiente mejora más barata está en el codebook y en las etiquetas, no en un modelo más grande.

1. Codebook: definir inv, separar temp, crec como residual
2. Reetiquetar lo que marca cleanlab, con aprendizaje activo
3. Umbrales por costo para no y cred, con monitoreo

Apéndice A1. Ablación completa: el intervalo de E9b no se traslapa con el de B2.

Bloque	Experimento	Qué cambia	Macro F1 [IC 95%]	Micro F1	Hamming	temp F1
Líneas base	B0	No predecir ninguna etiqueta	0.000 [0.000, 0.000]	0.000	0.1143	0.000
	B1	Siempre la etiqueta más frecuente (inv)	0.051 [0.050, 0.053]	0.323	0.1451	0.000
TF-IDF + LR	B2, umbral 0.5	Sin umbrales ajustados ni reglas	0.664 [0.652, 0.676]	0.726	0.0683	0.370
	B2, umbrales	+ umbrales ajustados out-of-fold	0.666 [0.654, 0.678]	0.735	0.0639	0.374
	B2, al menos una	+ regla de al menos una etiqueta	0.668 [0.656, 0.680]	0.734	0.0658	0.378
	B2, no excluyente	+ regla de no excluyente (sin la anterior)	0.669 [0.657, 0.682]	0.738	0.0630	0.380
	B2 (referencia)	Umbrales + ambas reglas	0.671 [0.659, 0.684]	0.736	0.0650	0.384
	B2_margin	Al menos una, por mayor margen	0.673 [0.661, 0.686]	0.738	0.0646	0.401
	B3	Cadena de clasificadores	0.665 [0.652, 0.678]	0.735	0.0642	0.372
	B2_codebook	B2 + 10 similitudes con el codebook	0.666 [0.654, 0.679]	0.731	0.0655	0.392
Embeddings congelados	E1_e5	e5 + LR, umbral 0.5	0.580 [0.568, 0.592]	0.653	0.0888	0.236
	E2_e5	+ similitudes con el codebook	0.583 [0.570, 0.594]	0.655	0.0881	0.238
	E3_e5	+ umbrales y reglas	0.601 [0.589, 0.613]	0.672	0.0811	0.250
	E1_mpnet	mpnet + LR, umbral 0.5	0.574 [0.561, 0.586]	0.640	0.0933	0.288
	E2_mpnet	+ similitudes con el codebook	0.573 [0.560, 0.585]	0.641	0.0931	0.294
	E3_mpnet	+ umbrales y reglas	0.588 [0.574, 0.601]	0.651	0.0871	0.291
e5 con fine-tuning	E4	Probabilidades de la cabeza	0.701 [0.688, 0.714]	0.758	0.0575	0.410
	E5	Embedding con fine-tuning + LR	0.637 [0.625, 0.649]	0.693	0.0749	0.320
	E6	Embedding + probabilidades B2 + codebook, LR	0.642 [0.629, 0.653]	0.693	0.0762	0.271
	E7	Mismas features, LightGBM	0.702 [0.691, 0.715]	0.759	0.0578	0.355
Estructura y mezcla	E8	no contra negocio primero, luego E7	0.693 [0.680, 0.706]	0.753	0.0585	0.377
	E9	Mezcla B2 + E7	0.712 [0.700, 0.724]	0.766	0.0562	0.399
	E9b (seleccionado)	Mezcla B2 + E4	0.715 [0.703, 0.727]	0.771	0.0547	0.421

Apéndice A2. Partir por filas infla poco las métricas, y la selección quedó fija antes del único uso del test.

Métrica	Partición agrupada	Partición por filas
Macro F1	0.671	0.679
Hamming loss	0.0650	0.0633
Samples F1	0.748	0.751
temp F1	0.384	0.420
Samples F1 en las 199 filas con duplicado en otro fold	0.701	0.714

2 de octubre de 2026, hora local (UTC-5)

15:11 a 15:12



E9b elegido en CV

macro F1 0.7152; la selección queda escrita en la config

15:37



Única evaluación en test

E9b y B2; hash de la config:
1f3cf3b6c783

19:33 a 19:36



Registro

config de test reconstruida con el mismo hash; primer commit y tag

Apéndice A3. En test, E9b supera a B2 en F1 en las 10 etiquetas; temp sigue siendo la más baja.

Etiqueta	Descripción	Precisión	Recall	F1	PR-AUC	Soporte	F1 de B2
crec	crecimiento sin uso específico	0.587	0.693	0.635	0.697	88	0.553
cred	pago de deudas	0.779	0.828	0.803	0.856	64	0.791
equ	equipo	0.837	0.843	0.840	0.912	299	0.831
inic	iniciar un negocio	0.651	0.719	0.683	0.728	57	0.630
inv	inventario o mercancía	0.797	0.903	0.847	0.911	349	0.836
mkt	marketing	0.842	0.941	0.889	0.967	51	0.873
no	no destinado a capital de trabajo	0.839	0.788	0.812	0.836	66	0.719
renta	renta	0.638	0.779	0.701	0.739	113	0.677
sueldo	nómina	0.580	0.906	0.707	0.757	32	0.639
temp	ventas de temporada	0.375	0.429	0.400	0.393	28	0.338