

¿Se puede clasificar mejor el destino del crédito?

Clasificación multietiqueta de los motivos de crédito de solicitudes PyME, en texto libre y en español

Sí: con una evaluación más estricta, bajé la Hamming loss de 0.0682 a 0.0521

0.0521

Hamming loss en test

contra 0.0682 reportado por Konfío; mi IC 95% llega a 0.0571

0.732

Macro F1 en test

+0.043 [+0.020, +0.065] sobre mi propia línea base TF-IDF

12%

del error restante es del modelo

el resto viene de la convención de etiquetado y del ruido en las etiquetas

RECORRIDO CRISP-DM

1 Negocio

slide 3

2 Datos

slide 4

3 Preparación

slide 5

4 Modelado

slide 6-7

5 Evaluación

slide 8-9

6 Despliegue

slide 10

El destino del crédito llega en texto libre; etiquetarlo lo convierte en una señal de riesgo y de producto

Respuesta del solicitante	Etiquetas
Invertiré en equipo de transporte tractocamión	equ
Compra de inventario, publicidad y capacitación	inv, mkt
Transferir otro crédito que está muy caro	cred
Quiero irme de vacaciones en mayo	no

CÓMO DEFINÍ EL ÉXITO

- Macro F1 como métrica principal, fijada antes de modelar: temp (2.8%) pesa igual que inv (34.7%)
- no (consumo personal) y cred (refinanciamiento) son señales de riesgo: priorizo su recall
- 10 etiquetas, una respuesta puede tener varias: problema multietiqueta

PUNTO DE PARTIDA DE KONFÍO

Machine learning

Embeddings de oración (LASER) + regresión logística, una por etiqueta

Deep learning

CNN con embeddings fastText sobre texto lematizado

0.06821

Hamming loss

67%

precisión promedio

Su etiqueta más débil: temp, la menos poblada

Los datos traían defectos estructurales y un desbalance fuerte: temp aparece en solo 2.8% de las respuestas

Lo que encontré	Lo que decidí
~22 registros fusionados en una celda	Los recuperé línea por línea
Codificación rota en ~42% de las filas	La corregí con ftfy
9 textos sin sentido y 1 no textual	Los eliminé, con su motivo registrado
58 grupos de texto idéntico con etiquetas distintas	Los conservé: miden el ruido de anotación
inv no aparece en el codebook	Asumí inventario o mercancía

6,691


respuestas limpias

86%

con una sola etiqueta

11

palabras de mediana



Porcentaje de 6,691 respuestas limpias

Preparé dos versiones del texto, una para cada familia de modelos, y una partición sin fugas

Rama léxica, para TF-IDF

Normalización agresiva: lo que importa son las palabras clave

1. Corrijo la codificación y los espacios
2. Paso todo a minúsculas
3. Quito acentos (conservo la ñ), dígitos y puntuación
4. Lematizo con spaCy (es_core_news_sm)
5. Stopwords propias que conservan no y sin

Rama transformer, para e5

Texto casi original: el encoder preentrenado lo espera así

1. Corrijo la codificación y los espacios
2. Conservo acentos, mayúsculas y puntuación
3. Antepongo el prefijo "query: " que pide e5
4. Corto a 96 tokens: cubre el 100% de las respuestas

FEATURES QUE CREÉ

- N-gramas TF-IDF de palabras (1-2) y de caracteres (3-5)
- 10 similitudes coseno contra las definiciones del codebook
- Embeddings del e5 con fine-tuning, generados out-of-fold

PARTICIÓN AGRUPADA POR TEXTO NORMALIZADO

Fold 1

Fold 2

Fold 3

Fold 4

Fold 5

Test


CV: 5,703 filas para elegir modelo, mezcla y umbrales

988 filas, usado una vez


Un texto repetido nunca queda a ambos lados; estratificación iterativa multietiqueta

Cumplí el punto de partida pedido, deep learning que genera features para un modelo clásico, y luego lo superé

PUNTO DE PARTIDA PEDIDO · E7



MODELO FINAL · E9b: MEZCLA DE DOS MODELOS QUE SE EQUIVOCAN DISTINTO



TF-IDF fue difícil de superar: los embeddings congelados pierden y solo el fine-tuning lo supera

0.671

TF-IDF + regresión logística (B2)

Respuestas cortas que deciden palabras como nómina, renta o mercancía

0.601


e5 congelado + LR

Los embeddings generales difuminan justo esas palabras clave

0.715



Mezcla E9b

El e5 acierta en 1,000 filas donde B2 falla; B2 en 695 donde falla el e5



Evalué con macro F1 e intervalos de confianza: en test, E9b supera a B2 y a la Hamming loss de Konfío

Métrica	Por qué la uso
Macro F1 (principal)	Cada etiqueta pesa igual: temp y sueldo cuentan tanto como inv
Hamming loss	Solo para comparar con Konfío: no predecir nada ya da 0.114
PR-AUC y samples F1	Calidad del ranking por etiqueta y acierto por solicitud
IC 95% por bootstrap de grupos	Toda diferencia con intervalo; el test se usó una sola vez





E9b menos B2, mismo test: +0.043 de macro F1 [+0.020, +0.065]
Su "precisión promedio de 67%" es ambigua: la PR-AUC media (0.78) y la precisión micro (0.75) la superan; la macro (0.69) no es concluyente

temp sigue siendo la más débil, y la mayor parte del error restante viene de las etiquetas, no del modelo

Mejoro en las 10 etiquetas; temp sube de 0.34 a 0.40 pero mezcla temporada y ciclo de cobro

Revisé 50 errores a mano: solo 12% es del modelo; 58% es convención de etiquetado



50 errores revisados a mano (CV), IC 95% de Wilson

Lo desplegaría como API: responde en 32 ms en CPU y manda a revisión humana los casos de riesgo

31.7 ms


p50 en CPU

47.6 ms

p95 en CPU

5.3 ms

B2 de respaldo



E9b (seleccionado)

Etiquetas: cred

Requiere revisión humana: etiqueta de riesgo: cred



Demo en vivo: la misma API, sin conexión a internet

La siguiente mejora más barata está en el codebook y en las etiquetas, no en un modelo más grande

LO QUE APRENDÍ

- Una buena línea base léxica ya iguala a LASER
- El fine-tuning gana porque falla distinto que TF-IDF
- El techo actual lo ponen las etiquetas: temp e inv mal definidas

LO QUE HARÍA DESPUÉS

1. Codebook: definir inv, separar temp en temporada y ciclo de cobro, crec como residual
2. Reetiquetar lo que marca cleanlab, con aprendizaje activo
3. Umbrales por costo para no y cred, con monitoreo

EL CÓDIGO

configs/	config y modelo fijo
src/intent/	datos, features, modelos
notebooks/	uno por fase CRISP-DM
reports/	reporte y resultados
tests/	pruebas pytest
app/	demo Streamlit

make data · train · evaluate · demo

Repositorio adjunto a esta entrega; los datos no se incluyen por ser confidenciales

¿Se puede clasificar mejor? Sí, y el siguiente salto viene de mejorar las etiquetas, no el modelo

Ablación completa en CV: el intervalo de E9b no se traslapa con el de B2

Experimento	Qué cambia	Macro F1 [IC 95%]	Micro F1	Hamming	temp F1
B0	No predecir ninguna etiqueta	0.000	0.000	0.1143	0.000
B1	Siempre la etiqueta más frecuente (inv)	0.051 [0.050, 0.053]	0.323	0.1451	0.000
B2, umbral 0.5	TF-IDF + LR, sin umbrales ni reglas	0.664 [0.652, 0.676]	0.726	0.0683	0.370
B2 (referencia)	+ umbrales out-of-fold y ambas reglas	0.671 [0.659, 0.684]	0.736	0.0650	0.384
B2_margin	Al menos una etiqueta, por mayor margen	0.673 [0.661, 0.686]	0.738	0.0646	0.401
B3	Cadena de clasificadores	0.665 [0.652, 0.678]	0.735	0.0642	0.372
B2_codebook	B2 + 10 similitudes con el codebook	0.666 [0.654, 0.679]	0.731	0.0655	0.392
E3_e5	e5 congelado + LR, umbrales y reglas	0.601 [0.589, 0.613]	0.672	0.0811	0.250
E3_mpnet	mpnet congelado + LR, umbrales y reglas	0.588 [0.574, 0.601]	0.651	0.0871	0.291
E4	Cabeza del e5 con fine-tuning	0.701 [0.688, 0.714]	0.758	0.0575	0.410
E5	Embedding con fine-tuning + LR	0.637 [0.625, 0.649]	0.693	0.0749	0.320
E6	Embedding + prob. B2 + codebook, LR	0.642 [0.629, 0.653]	0.693	0.0762	0.271
E7	Mismas features, LightGBM	0.702 [0.691, 0.715]	0.759	0.0578	0.355
E8	Primero no contra negocio, luego E7	0.693 [0.680, 0.706]	0.753	0.0585	0.377
E9	Mezcla B2 + E7	0.712 [0.700, 0.724]	0.766	0.0562	0.399
E9b (seleccionado)	Mezcla B2 + E4	0.715 [0.703, 0.727]	0.771	0.0547	0.421